



Kolektif Öğrenme 3. Ödev Raporu

Öğrenci Adı: Emir Kaan SALT

Öğrenci Numarası: 24501073

1. Amaç ve Kullanılan Yöntemler

1.1 Çalışmanın Amacı

Bu çalışmanın temel amacı, Türkçe çoktan seçmeli sınav sorularında (A–E şıkları) doğru cevabı üretebilen bir dil modelinin performansını artırmak ve bu süreçte farklı ödül stratejilerinin model davranışı üzerindeki etkisini incelemektir.

Özellikle aşağıdaki problemler hedeflenmiştir:

- Modelin yalnızca tek bir şıkka çökmesi (mode collapse),
- Format talimatına uysa bile doğruluk ve çeşitlilik açısından zayıf kalması,
- Tek bir eğitim yaklaşımının bu sorunları çözmede yetersiz kalması.

Bu bağlamda, çalışmada yalnızca tek bir model eğitmek yerine:

- Supervised Fine-Tuning (SFT) ile başlangıç modeli oluşturulmuş,
- Ardından GRPO (Generative Reinforcement Policy Optimization) yöntemi kullanılarak farklı ödül fonksiyonları ile model davranışı yönlendirilmiş,
- Son olarak bu modeller birleştirilerek (model merging) daha dengeli bir çıktı elde edilmesi amaçlanmıştır.

2. Veri Kümesi Seçimi ve Alt Küme Oluşturma

Veri kümesinin tamamı yerine, deneylerin daha kontrollü ve anlamlı yürütülebilmesi amacıyla belirli sınav türleri ve konu başlıkları seçilerek bir **alt küme (subset)** oluşturulmuştur.

Alt küme oluşturulurken, özellikle **sayısal ve sözel muhakeme** gerektiren, çoktan seçmeli sınav formatına uygun bölümler tercih edilmiştir. Bu doğrultuda aşağıdaki bölümler ve konular seçilmiştir.

2.1 Seçilen Bölümler ve Konular

KPSS Denemeleri bölümünden seçilen konular;

- Matematik Denemeler
- Matematik Konu Soruları
- Genel Yetenek Denemeler

KPSS bölümünden seçilen konular:

- Sözel Mantık
- Sayısal Mantık
- Matematik
- Geometri

YGS Denemeleri bölümünden seçilen konular:

- Türkçe Konu Soruları
- Türkçe Denemeler
- Geometri Konu Soruları
- Matematik Konu Soruları

Bu seçimle birlikte, hem sözel hem de sayısal becerileri ölçen, farklı zorluk seviyelerine sahip soruların yer aldığı dengeli bir alt küme elde edilmesi amaçlanmıştır.

3. Alt Kümenin Birleştirilmesi ve Karıştırılması (Shuffle)

Seçilen bölümlere ait veriler ayrı ayrı filtrelendikten sonra, tek bir veri kümesi hâline getirilmiştir. Bu işlem, farklı sınav türlerinden gelen soruların birlikte değerlendirilmesini sağlamaktadır. Birleştirme işlemi sonrasında, veri sıralamasının modele olası bir yanlışlık kazandırmasını önlemek amacıyla **rastgele karıştırma (shuffle)** işlemi uygulanmıştır.

4. Prompt Tasarımı

Modelin yalnızca doğru şıkkı üretmesini sağlamak amacıyla her bir soru için özel bir **prompt yapısı** tasarlanmıştır. Prompt, üç temel bileşenden oluşmaktadır:

- Soru metni
- A–E seçenekleri
- Açık ve kısıtlayıcı talimat

Her prompt aşağıdaki genel şablona sahiptir:

- “Soru:” başlığı altında soru metni
- “Seçenekler:” başlığı altında A–E seçenekleri
- Talimat kısmında, modelden yalnızca doğru seçeneğin harfini üretmesi istenmektedir

5. Etiketleme ve Veri Temizleme

Her soru için doğru cevap, veri kümesinde bulunan cevap alanından alınarak A–E harf karşılığına dönüştürülmüştür. Bu işlem sırasında:

- Geçersiz veya eksik cevaba sahip örnekler,
- Seçenek sayısı eksik olan sorular,
- Prompt üretilmeyen örnekler

veri kümesinden çıkarılmıştır.

6. Eğitim ve Test Veri Bölmesi

Temizlenmiş ve karıştırılmış alt veri kümesi, oran koruyucu (stratified) bir yöntemle eğitim ve test setlerine ayrılmıştır:

- **Eğitim seti (Train):** 1000 örnek
- **Test seti (Test):** 500 örnek

Bu bölme işlemi sırasında, A–E cevaplarının dağılımının her iki kümede de benzer kalmasına özellikle dikkat edilmiştir.

7. Supervised Fine-Tuning (SFT)

Bu aşamada amaç, temel dil modelinin (GPT-2 tabanlı) Türkçe çoktan seçmeli sınav sorularına görev uyumlu hale getirilmesidir. Modelin, verilen soru ve seçenekler arasından yalnızca doğru seçeneğin harfini üretmesi hedeflenmiştir.

7.1 SFT Eğitiminin Amacı

SFT aşamasında aşağıdaki hedefler gözetilmiştir:

- Modelin soru–cevap bağlamını öğrenmesi,
- Seçenekler arasından mantıklı bir tercih yapabilmesi,
- Belirlenen çıktı formatlarına alıştırılması,
- GRPO aşaması için başlangıç (initial policy) oluşturulması.

Bu nedenle SFT, nihai performans artışı için değil; ödül tabanlı öğrenmeye uygun bir başlangıç noktası sağlamak amacıyla kullanılmıştır.

7.2 Çoklu Formatlı Çıktı Tasarımı

Modelin farklı çıktı formatlarını öğrenmesi amacıyla SFT sırasında çoklu format yaklaşımı benimsenmiştir. Eğitim verisinde, doğru cevap aşağıdaki üç formattan biriyle sunulmuştur:

- Tek harf formatı
- Önekli format
- JSON formatı

8. GRPO (Generative Reinforcement Policy Optimization)

SFT sonrasında model, ödül fonksiyonları ile yönlendirilen GRPO yöntemi kullanılarak eğitilmiştir. GRPO'nun temel amacı, model davranışını yalnızca etiketli veriye değil, tanımlanan ödüllere göre optimize etmektir.

8.1 GRPO'nun Kullanım Gerekçesi

Bu çalışmada GRPO tercih edilmesinin temel nedenleri şunlardır:

- SFT sonrasında modelin tek bir şıkka çökme (mode collapse) eğilimi göstermesi,
- Format uyumunun yüksek olmasına rağmen doğruluk ve çeşitliliğin düşük kalması,

- Farklı ödöl stratejilerinin model davranışı üzerindeki etkisinin incelenmek istenmesi.

GRPO, bu problemleri doğrudan hedefleyen bir optimizasyon çerçevesi sunmaktadır.

9. Baseline Ödöl Fonksiyonu

Çalışmada referans noktası olarak kullanılan baseline ödöl fonksiyonu, ödev tanımına uygun şekilde yalnızca iki bileşenden oluşmaktadır:

- Doğruluk (Accuracy)
- Format Uygunluğu (Format)

Herhangi bir ceza (penalty) veya ek terim baseline aşamasında kullanılmamıştır.

9.1 Baseline Ödöl Tanımı

Baseline ödölü aşağıdaki şekilde tanımlanmıştır:

- Doğru format: 0.1
- Doğru cevap: 0.9
- Toplam maksimum ödöl: 1.0

10. Alternatif Ödöl Fonksiyonları

Baseline'ın yetersizliği göz önünde bulundurularak, dört farklı alternatif ödöl fonksiyonu tasarlanmıştır. Bu fonksiyonların ortak özelliği:

- Baseline yapısını korumaları,
- Sadece ek bir bileşen ile genişletilmeleridir.

10.1 Alternatif 1 – Çeşitlilik (Diversity) Tabanlı Ödöl

İlk alternatif modelde amaç, modelin aynı prompt için ürettiği birden fazla cevabın çeşitliliğini artırmaktır. GRPO sırasında her bir prompt için birden fazla çıktı üretildiğinden, bu çıktılar arasındaki farklılık ölçülebilmektedir.

Bu modelde:

- Aynı prompt için üretilen cevaplar analiz edilmiş,
- Üretilen farklı cevap harflerinin sayısı hesaplanmış,
- Çeşitlilik arttıkça modele 0.25 ödöl verilmiştir.

10.2 Alternatif 2 – Entropi (Entropy) Tabanlı Ödül

İkinci alternatif modelde çeşitlilik, doğrudan cevap dağılımının **entropisi** üzerinden teşvik edilmiştir. Entropi, modelin ürettiği cevapların ne kadar dengeli dağıldığını ölçen istatistiksel bir metriktir.

Bu modelde:

- Aynı prompt için üretilen cevapların olasılık dağılımı çıkarılmış,
- Bu dağılımın entropisi hesaplanmış,
- Yüksek entropi daha yüksek ödül ile teşvik edilmiştir.

10.3 Alternatif 3 – Format + Çeşitlilik Dengeli Ödül

Üçüncü alternatif modelde amaç, format uyumu ile çeşitlilik arasında daha dengeli bir ilişki kurmaktır. Önceki alternatiflerde gözlemlenen durum, çeşitlilik teşvik edilirken format kalitesinin zaman zaman bozulabilmesidir.

Bu nedenle bu modelde:

- Baseline format ödülü korunmuş,
- Çeşitlilik bonusu format uyumu sağlandığında daha etkili olacak şekilde düzenlenmiştir,
- Format dışı çıktılar için çeşitlilik ödülünün etkisi sınırlandırılmıştır.

10.4 Alternatif 4 – Davranış Dengeleyici (Penalty-Free) Ek Bileşen

Dördüncü alternatif modelde, klasik anlamda bir ceza uygulanmamış; bunun yerine, modelin aşırı tekrarlayan davranışlarının dolaylı olarak baskılanması hedeflenmiştir.

Bu modelde:

- Baseline ödülü korunmuş,
- Tekrarlayan cevap üretimlerinin katkısı azaltılmış,
- Ancak yanlış cevaplar için doğrudan negatif ödül verilmemiştir.

11. Model Birleřtirme

Alternatif ödöl fonksiyonları ile eğitilen modellerin her biri, model davranışının farklı bir yönünü iyileřtirmeyi hedeflemiřtir. Ancak yapılan deneyler göstermiřtir ki, tek başına hiçbir model hem doğruluk, hem format uyumu hem de cevap çeřitlilięi açısından ideal bir denge sağlayamamaktadır.

Bu nedenle çalışmanın son aşamasında, farklı ödöl fonksiyonlarıyla eğitilmiş modellerin güçlü yönlerini tek bir modelde birleřtirmek amacıyla model birleřtirme yaklaşımı uygulanmıřtır.

11.1 Birleřtirmenin Amacı

Model birleřtirmenin temel hedefleri řunlardır:

- Baseline modelin format uyumunu korumak,
- Alternatif modellerin getirdięi çeřitlilik ve davranıř farklılıklarını tek bir yapıda toplamak,
- Tek bir modele çökme problemini azaltmak,
- Ayrı ayrı eğitilmiş modeller arasında davranıřsal denge sağlamak.

11.2 Kullanılan Yöntem

Bu çalışmada model birleřtirme iřlemi için MergeKit kütüphanesi kullanılmıřtır. MergeKit, birden fazla HuggingFace uyumlu modelin aęırlıklarını belirli kurallar çerçevesinde birleřtirmeye olanak tanır.

Birleřtirme iřlemi řu özelliklere sahiptir:

- Baseline GRPO modeli (%40)
- Alternatif 1 (Çeřitlilik) (%15)
- Alternatif 2 (Entropi) (%15)
- Alternatif 3 (Format + Çeřitlilik) (%15)
- Alternatif 4 (Davranıř dengeleyici) (%15)

12. Deneysel Sonular ve Karşılaştırmalı Analiz


Bu bölümde, çalışmada elde edilen tüm modeller aynı test veri kümesi üzerinde değerlendirilmiş ve sonuçlar karşılaştırmalı olarak analiz edilmiştir.

Tüm modeller aşağıdaki koşullar altında test edilmiştir:

- Test seti: 500 örnek
- Üretim yöntemi: Greedy decoding
- Format kontrolü


12.1. Accuracy Karşılaştırması

- GRPO ile tanımlanan ödöl fonksiyonları, doğruluğu artırmada etkili olmamıştır.
- Bunun temel nedeni, modelin tek bir şıkka ökme (mode collapse) davranışdır.
- Merging işlemi doğruluğu artırmak yerine, farklı davranışları ortalayıp hafif bir doğruluk kaybına yol açmıştır.




12.2. Format Rate

- SFT aşamasında tanımlanan prompt ve format yapısı, model tarafından tamamen öğrenilmiştir.
- GRPO süreci format açısından ek bir kazanım sağlamamıştır, çünkü problem zaten çözülmüştür.




12.3. Dominant Answer Share

- Alternatif ödül fonksiyonları tek başına mode collapse'ı kıramamıştır.
- Ancak model birleştirme (merge), farklı modellerin parametrelerini harmanlayarak tek şık hakimiyetini kısmen azaltmıştır.




12.4. Entropy of Prediction Distribution (Tahmin Entropisi)

- Entropi ≈ 0 ise model tek cevaba kilitlenmiş demektir.
- Merged modelde C ve E cevapları birlikte üretilmeye başlanmıştır.
- Merged model, çeşitlilik açısından açık ara en iyi modeldir.



12.5. Prediction Distribution (A–E Dağılımı)

- Alternatif ödül fonksiyonları:
 - Çeşitlilik hedeflese de,
 - Mode collapse'ı kıramamıştır.
- Merge işlemi:
 - Farklı modellerdeki “tercih yönlerini” birleştirerek,
 - En azından **iki şık arasında dağılım** sağlamıştır.



13. Genel Değerlendirme

- SFT aşaması, modelin verilen prompt yapısını ve çıktı formatını öğrenmesi açısından başarılı olmuştur. Bu aşamadan sonra tüm modellerde format uyumu (format rate) %100'e ulaşmıştır.
- GRPO tabanlı baseline model, doğruluk ve format bileşenlerinden oluşan standart ödül fonksiyonuna rağmen, modelin tek bir şıkka çökme (mode collapse) davranışını engelleyememiştir. Model neredeyse tüm sorular için aynı cevabı üretmiştir.
- Alternatif ödül fonksiyonları, teorik olarak mode collapse problemini hedeflesede, pratikte tek başına bu sorunu çözmede yetersiz kalmıştır. Bu modellerde de baskın cevap oranı %100 seviyesinde kalmıştır.
- Tüm GRPO modellerinde doğruluk oranları birbirine çok yakın ($\approx$ %19) seyretmiş ve ödül fonksiyonları arasında anlamlı bir doğruluk farkı gözlemlenmemiştir. Bu durum, doğruluğun mevcut ödül tanımlarıyla sınırlı ölçüde optimize edilebildiğini göstermektedir.
- Model birleştirme (merge) yöntemi, tek başına eğitilen modellerde gözlemlenen mode collapse problemini kısmen azaltmıştır. Merged modelde baskın cevap oranı düşmüş ve birden fazla şıkka üretildiği bir dağılım elde edilmiştir.
- Genel olarak, bu çalışma göstermiştir ki:
 - Format öğrenimi SFT aşamasında büyük ölçüde çözülmektedir.
 - GRPO'da yalnızca ödül fonksiyonu tasarımı, tek şıkka çökme problemini çözmek için yeterli değildir.
 - Çeşitlilik problemi, model birleştirme gibi yapısal yöntemlerle daha etkili biçimde ele alınabilmektedir.